队伍编号	MC2608331
题号	C

中西医下的中老年人群高血脂风险评估与干预优化研究

摘要

随着老龄化加剧，高血脂症的精准防治已成为公共卫生领域的核心课题。针对传统预警单一与干预同质化的痛点，本文旨在构建融合中医体质的多维评估与防控体系。综合运用 XGBoost-SHAP、GAM 及 NSGA-II 算法，实现了核心致病指标萃取、风险自适应客观分层与长周期动态干预方案的最优匹配。

针对问题一，首先利用孤立森林检测模型识别出 50 例生理逻辑冲突样本，并采用随机森林多重插补算法完成特征重构与平滑处理。其次，运用 Spearman 秩相关检验与方差膨胀因子迭代消融算法，有效解耦高维特征空间的共线性冗余，初步筛选出 17 项统计独立的候选特征。随后，构建 XGBoost-SHAP 与代价敏感 LightGBM 融合模型，结合 K-Means++ 空间聚类算法，在双目标特征空间内最终萃取出 TC（总胆固醇）与 TG（甘油三酯）作为双效预警核心指标，其 SHAP 重要度分别为 1.54 与 1.19，Gain 增益分别达 1493.76 与 1730.81。最后，量化分析九种中医体质对高血脂发病风险的致病权重，明确痰湿质（0.0142）、阴虚质（0.0087）及气郁质（0.0076）为贡献度最高的三大核心致病体质。

针对问题二，首先采用靶向特征剥离策略剔除理化确诊指标，引入广义加性模型（GAM）结合样本基函数，将离散二元发病标签平滑映射为连续隐性生理风险概率测度，克服了目标变量泄露，模型 Brier 评分收敛至真实的 0.1206。其次，运用核密度估计（KDE）与拓扑微积分极值寻优算法，自适应锁定概率密度分布的自然波谷，客观界定出低（$p<0.75$）、中（$0.75\leq p<0.97$）、高（$p\geq 0.97$）三级风险截断阈值，实现各风险组 333 例样本的均衡分层。详情数据见附录，最后，构建 CART 全局代理决策树提取临床显性特征分层规则，分层标签保真度达 0.5467，并结合 FP-Growth 算法精准挖掘出高危人群“低 HDL → 高 TG”的核心致病特征组合，其支持度、置信度与提升度分别高达 0.1515、0.8333 与 1.5278。

针对问题三，首先，构建以期末痰湿积分与总干预费用双重最小化为目标的离散动态优化模型，并引入带精英保留策略的 NSGA-II 算法进行帕累托前沿寻优。随后，针对样本 ID 为 1、2、3 的同质化患者（初始积分 70.0，最高耐受度 3 级），求得非对称最优时序方案：首月实施 3 级强度每周 9 次的激进干预，后 5 个月转为 1 级强度每周 10 次的维持干预，使期末积分骤降至 40.14 分，总成本仅 1218.00 元。最后，复用 XGBoost-SHAP 框架提炼匹配规律，明确初始积分突破 60 分即触发高强度跃迁阈值，且高活动评分与低龄驱动“激进型”方案，高龄或低活动分则锁定“温和维持型”策略。

关键词： XGBoost-SHAP 模型　CART 决策树　FP-Growth 算法　NSGA-II 算法

目录

一、问题重述 3
1.1 问题背景 3
1.2 问题复述 3
二、问题分析 3
2.1 问题一分析 3
2.2 问题二分析 4
2.3 问题三分析 4
三、模型假设 4
四、符号说明 4
五、数据预处理 5
5.1 孤立森林无监督异常检测 5
5.2 随机森林多重插补 5
六、问题一模型建立与求解 6
6.1 痰湿表征与高血脂预警的特征初筛 6
6.1.1 基于非参数秩相关的特征初筛 6
6.1.2 基于 VIF 诊断的共线性解耦模型 7
6.1.3 特征价值的双目标融合判定 7
6.1.4 结果分析 7
6.2 痰湿表征的贡献度量化与筛选 9
6.2.1 XGBoost 非线性拟合底座构建 9
6.2.2 基于合作博弈论的 SHAP 边际归因 9
6.2.3 痰湿体质核心特征的全局提纯 10
6.2.4 结果分析 10
6.3 高血脂发病风险预警模型构建与验证 11
6.3.1 LightGBM 分类底座与概率映射 11
6.3.2 代价敏感交叉熵损失函数构建 12
6.3.3 基于高斯过程的贝叶斯超参数寻优 12
6.3.4 全局预警特征重要度的量化提取 13
6.3.5 结果分析 13
6.4 痰湿表征与高血脂预警的特征筛选 14
6.4.1 双目标特征空间构建与无量纲化 14
6.4.2 基于轮廓系数的最佳簇数自适应寻优 14
6.4.3 K-Means++ 聚类迭代与质心优化 15
6.4.4 基于理想点距离的双效核心特征萃取 15

6.4.5 结果分析 15
6.5 九种体质对发病风险的贡献度差异分析 16
6.5.1 构建模型 16
6.5.2 结果分析 17
七、问题二模型建立与求解 17
7.1 构建高血脂症风险预警分层模型 17
7.1.1 靶向特征剥离与基础映射空间构建 18
7.1.2 惩罚似然目标函数的构建与模型求解 18
7.1.3 结果分析 19
7.2 低、中、高三级风险输出 20
7.2.1 概率密度空间的非参数重构 20
7.2.2 拓扑波谷寻优 21
7.2.3 三级风险区间的自适应界定 21
7.2.4 结果分析 22
7.3 特征选取与高风险人群组合分析 22
7.3.1 全局特征空间重构与临床逻辑对齐 22
7.3.2 特征分层阈值提取 23
7.3.3 高危人群特征组合挖掘 23
7.3.4 结果分析 24
八、问题三模型建立与求解 24
8.1 构建多目标优化模型 24
8.1.1 决策变量与系统状态描述 25
8.1.2 动态演化机制与状态转移方程 25
8.1.3 多目标优化函数的构建 25
8.1.4 系统约束条件的确定 26
8.1.5 结果分析 26
8.2 匹配规律分析 27
九、模型优缺点与评价 28
9.1 模型的优点 28
9.2 模型不足 29
十、模型改进与推广 29
10.1 模型改进 29
10.2 模型推广 29
十一、参考文献 30
十二、附录 30

一、 问题重述

1.1 问题背景

随着人口老龄化进程的不断加剧，中老年高血脂症的防治已成为公共卫生领域的重大挑战。然而，在实际临床与慢病管理场景中，现有的风险评估往往单一依赖血常规指标，缺乏对中医偏颇体质及日常活动能力等多维特征的综合考量，导致早期精准预警与防治干预效能不足。因此，量化中医体质评分与活动量度对高血脂发病风险的影响机制，构建科学的多维度风险预警评估及个性化干预优化模型，成为了打破现有慢病防控壁垒、实现中西医结合精细化调治的核心课题。

1.2 问题复述

问题一：基于血常规体检与活动量表多维数据，要求运用特征降维与选择方法，提取能有效表征痰湿体质严重程度及预警高血脂发病风险的核心指标，并构建综合评价模型以量化探究九种中医体质对该疾病发病风险的贡献度差异规律。

问题二：基于多维度指标特征，要求构建高血脂症的分级风险预警模型，以实现低、中、高三级发病风险的精准分类与评估，并科学界定各级风险对应的特征分层阈值选取依据。在此基础上，需进一步探究并提取痰湿体质高危人群的核心病理特征组合模式，结合数据驱动规律与医学机理，对该特征组合的内在关联性与预警结果的合理性进行合理的解释。

问题三：基于“痰湿体质”确诊患者的个体特征与中医干预原则，要求在满足身体耐受度与经济预算的双重约束下，以体质积分降幅最大化及干预成本最小化为优化目标，构建多目标优化决策模型。进而，量化探究并明确异质性患者特征组合与最优干预策略之间的映射匹配规律，最终实现面向不同特征群体及特定临床个案的长期（6 个月）个性化精准干预方案的科学求解与制定。

二、 问题分析

2.1 问题一分析

针对问题一，本问题本质上是一个融合多源异构医疗数据的双目标非线性特征提纯与博弈论归因评价问题。首先，考虑到临床生化指标与活动量表数据分布的非正态性以及多维生理变量间的强耦合特性，构建“过滤-解耦”初筛机制，运用 Spearman 秩相关系数进行单调映射关联的特征粗筛，并引入方差膨胀因子（VIF）迭代算法进行自适应的共线性特征消融。其次，为了同时满足“有效表征痰湿体质”与“预警高血脂发病风险”的非公度双重目标，分别构建两套非线性代理底座：一方面利用 XGBoost 集成树模型拟合痰湿积分，并结合 SHAP 合作博弈理论精准量化各特征对体质偏颇的边际归因重要度；另一方面，针对临床医疗小样本数据的严重类别不平衡现象，构建代价敏感 LightGBM 分类预警模型，借助贝叶斯优化高效寻优并提取高血脂维度的全局特征信息

增益。随后，为打破双重评价标准间的量纲壁垒，运用 K-Means++ 无监督空间聚类算法，在标准化的二维双目标特征平面内自适应寻优轮廓系数，通过极小化簇质心与理想双优极值点间的欧氏距离，客观萃取出兼顾双重效能的关键指标群。最后，在确立核心指标池的基础上，进一步复用 XGBoost-SHAP 非线性归因架构，直接以高血脂症发病标签为目标函数，对九种中医体质得分特征空间进行高精度拟合与致病权重剥离，最终量化并输出各类体质分型对高血脂发病风险的绝对贡献度差异规律与层级排序结论。

2.2 问题二分析

针对问题二，本问题旨在通过融合多维度特征构建高血脂症的分级风险预警模型，本质上是一个复杂的非参数概率密度估计与多维特征分类关联规则挖掘问题。首先，为了克服离散二元标签导致模型退化及“目标变量泄露”的缺陷，采用靶向特征剥离策略，并引入广义加性模型（GAM）结合样条基函数，以此突破严格线性约束，将确诊标签平滑映射为表征隐性生理发病风险的连续概率测度。其次，为实现低、中、高三级风险的客观分层，引入基于核密度估计（KDE）的拓扑寻优算法，通过捕捉概率密度分布的自然波谷作为自适应截断边界，从而避免主观设定阈值带来的认知偏差。最后，运用分类与回归树（CART）作为全局代理模型提取显性的特征分层阈值依据，并结合 FP-Growth 算法进行关联规则挖掘，以解耦高风险人群的非线性协同致病因素，最终输出白盒化的临床判定规则与核心共病特征组合。

2.3 问题三分析

针对问题三，本问题旨在为“痰湿体质”确诊患者制定兼顾健康效益与经济成本的长周期干预策略，本质上属于一个典型的多目标离散动态约束优化问题。首先，考虑到阶段干预对系统状态演化存在的非线性累积影响以及多重生理耐受度红线限制，构建以期末体质积分与干预总花费双重最小化为核心的评价体系。其次，为有效处理变量离散且约束条件复杂的帕累托前沿求解，引入带精英保留策略的非支配排序遗传算法（NSGA-II）进行全局自适应寻优；随后，为了进一步探究异质性特征与决策间的深层匹配逻辑，复用 XGBoost-SHAP 架构对干预强度标签进行非线性归因分析。最后，依托所建模型与理想点法，系统输出特定临床个案在长期动态干预下的最优时序演化轨迹，并量化提炼出多维生理特征驱动下的方案自适应匹配法则。

三、 模型假设

1. 假设检测出的离群异常特征系随机测量误差所致，不存在系统性数据记录偏差。
2. 假设多维医疗特征对病理状态的非线性边际贡献严格满足博弈论可加性公理。
3. 假设人群向高血脂症演化的隐性生理发病风险在特征空间内连续、平滑且可微。
4. 假设在六个月的动态干预周期内，患者处于封闭系统，无突发重大疾病的干扰。

5. 假设分级活动干预对痰湿积分的逐月衰减效应是确定性的，忽略个体随机波动。

四、 符号说明

符号	说明	单位
$\phi_i(x)$	合作博弈论下特征对风险预测的边际贡献值	–
I_j	多维生理特征对目标的绝对重要度指数	–
p	广义加性模型平滑的高血脂隐性发病概率	–
$\hat{f}(p)$	非参数核密度估计的发病风险连续概率密度	–
VIF_i	候选医疗特征的方差膨胀因子	–
S_m	第 m 月初患者痰湿体质积分系统状态变量	分
x_m	动态规划第 m 月分级活动干预强度决策变量	级
y_m	动态规划第 m 月每周活动干预频率决策变量	次/周
ΔS_m	多维干预策略下患者单月痰湿体质积分非线性下降率	–
$C_{act}(x_m)$	特定干预强度 x_m 的单次训练单位经济成本	元/次
$C_{TCM}(S_m)$	随当月体质积分动态匹配的中医分级调理月度刚性成本	元/月

五、 数据预处理

由附件 1 可知，数据集共包含 1000 个样本与 37 个字段，高度集成了受检者的中医体质得分、日常生活活动能量表及西式生化血液指标等多模态医疗特征。经初步的数据分析确认，原始数据集完整，无缺失值和重复值。然而，鉴于医学数据的强多维耦合特性，即使所有指标均处于各自的单变量合理阈值内，高维空间中仍极易隐匿由生理逻辑冲突引发的结构性异常。为保证后续风险预警与分型分类模型的收敛稳定性、防止局部极端梯度扰动，同时兼顾医疗小样本数据的使用性，本小节对原始数据进行了系统性的高维无监督异常探测与靶向特征重构处理。

5.1 孤立森林无监督异常检测

传统的异常值检测方法，无法捕捉本数据集中中医体质、生化指标及量表得分间错综复杂的生理联动约束。因此，引入孤立森林无监督检测模型 [3]，在严格规避“样本 ID”与“目标标签”导致数据穿越的前提下，提取其余 34 维生理与量表特征构建联合特征空间。基于高维特征切分路径的期望长度来度量样本的异常程度。依据医学罕见病理组合的先验分布，设定异常污染率为 0.05，模型最终精准甄别出 50 例在多变量联合分布上严重偏离正常生理流形的离群样本行，累计有 1850 处疑似逻辑冲突的异常特征

坐标。

5.2 随机森林多重插补

针对孤立森林检出的 50 例异常样本，考虑到数据总样本量小，直接剔除效果不佳，容易错杀患有复杂并发症的真实罕见病例，从而削弱模型的泛化能力。为此，基于随机森林的多重插补算法进行定向修正，相关基础代码由 Doubao 辅助编写 [2]。下表是检测到的异常值和处理后的部分结果，详情见佐证材料。

表 1: 核心特征异常值预处理前后对比展示抽样表

样本 ID	数据状态	阳虚质得分	痰湿质得分	ADL 总分	TG	BMI
10	处理前	2	15	28	3.24	24.16
	处理后	20	33	23	2.48	22.12
33	处理前	36	15	34	3.04	23.01
	处理后	20	28	24	2.62	21.57
91	处理前	3	28	31	2.25	18.67
	处理后	18	27	25	2.75	21.99
119	处理前	27	21	15	3.28	19.85
	处理后	22	24	27	2.76	22.31
156	处理前	9	29	33	2.60	19.42
	处理后	24	34	21	2.59	22.31

由表 1 可知，经过“双森林”机制处理后，原始数据中由测量误差或极端病理突变引发的毛刺数据得到了高精度的平滑吸收。相较于处理前，重构后的特征集在标准差与极差跨度上呈现出更为稳健的分布收敛态势，消解了多维生理变量间的自相矛盾与逻辑断层。其特征一致性与结构纯净度亦得到了显著跃升，为后续模型建立与求解，提高可行性。

六、 模型建立与求解

6.1 问题一：XXX 模型的建立

6.1.1 数据预处理

对原始数据进行标准化处理，公式为：

$$x_i' = \frac{x_i - \min(x)}{\max(x) - \min(x)} \tag{1}$$

式(1)将数据映射到 $[0, 1]$ 区间，消除量纲影响。

6.1.2 模型构建

建立 **XXX** 优化模型（如“非线性规划、微分方程”），目标函数为：

$$\min f(\boldsymbol{X}) = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{2}$$

约束条件：

$$\begin{cases} x_1 + x_2 \leq 100, \\ 0 \leq x_i \leq 50 \quad (i = 1, 2, \ldots, n), \\ g(\boldsymbol{X}) \leq 0 \quad \text{（XXX 约束，如“能量守恒”）}. \end{cases}$$

6.2 问题一：模型求解

采用 **XXX** 算法（如“遗传算法、Lingo 求解器”）求解模型(2)，步骤：

1. 初始化：生成 $N = 100$ 个种群，每个个体维度为 $n = 5$；
2. 适应度计算：根据式(2)计算适应度；
3. 遗传操作：选择（轮盘赌）、交叉（概率 0.8）、变异（概率 0.1）；
4. 终止条件：迭代 1000 次或精度达到 10^{-6}。

求解得最优解：$\boldsymbol{X}^* = (x_1^*, x_2^*, \ldots, x_n^*)$，目标函数值 $f(\boldsymbol{X}^*) = XXX$。

6.3 结果可视化（图表示例）

模型预测结果与实际数据对比如图1所示：图1中，拟合误差小于 **5%**，验证了模型有效性。

图 1: 模型预测结果对比（实线：预测值；散点：实际值）

七、 模型检验

通过残差分析、灵敏度分析检验模型：表2显示，残差统计量较小，模型拟合效果良好。

表 2: 模型残差统计

指标	均值	标准差
残差	0.021	0.015
相对误差	1.2%	0.8%

八、 模型优缺点评价

8.1 优点

1. 考虑 **XXX** 复杂因素（如“时变特性、多约束”），适应性强；
2. 求解方法高效稳定（如“遗传算法全局搜索”），适用于大规模问题；
3. 结果可解释性强（如“参数对应物理意义”），便于决策。

8.2 缺点与改进方向

- 缺点：忽略 **XXX** 随机因素（如“测量噪声”），导致鲁棒性不足；
- 改进：引入蒙特卡洛模拟、鲁棒优化，提升模型抗干扰能力。

九、 参考文献

[1] 作者. 书名 [M]. 出版地：出版社，年份.（如：姜启源. 数学模型 [M]. 北京：高等教育出版社，2011.）

[2] 作者. 论文标题 [J]. 期刊名，年，卷 (期)：页码.（如：张三. 优化算法研究 [J]. 应用数学，2020，33(2)：12-18.）

[3] `https://example.com`（在线资源，需标注访问日期：2025-07-21）

十、 附录

10.1 附录 1：核心代码

以下是求解模型的 **Python** 核心代码（完整代码见附件）：

Listing 1: 遗传算法实现

```python
import numpy as np

def fitness_function(X):
"""目标函数：式\eqref{eq:objective}"""
y_pred = ...  # 模型预测值
return np.sum((y_true - y_pred)**2)

def genetic_algorithm(pop_size, num_gens):
"""遗传算法主函数"""
pop = np.random.uniform(0, 1, (pop_size, n_dim))  # 初始化种群
for gen in range(num_gens):
```

```
        fitness = np.apply_along_axis(fitness_function, 1, pop)
        # 选择、交叉、变异操作...
        new_pop = ...
        pop = new_pop
        return pop[np.argmin(fitness)]  # 返回最优解
```